

U-Net : Convolutional Networks for Biomedical Image Segmentation

2022.11

정 승 기



CONNECTEVE

목 차 Contents

1. Introduction
2. U-Net architecture
3. Overlap-tile strategy
4. Training
5. Experiments
6. Conclusion

1.1 Introduction

U-Net은 생물학적인 영상에서 Segmentation을 위해 제안된 네트워크

1.2 Segmentation




Fig. 1.

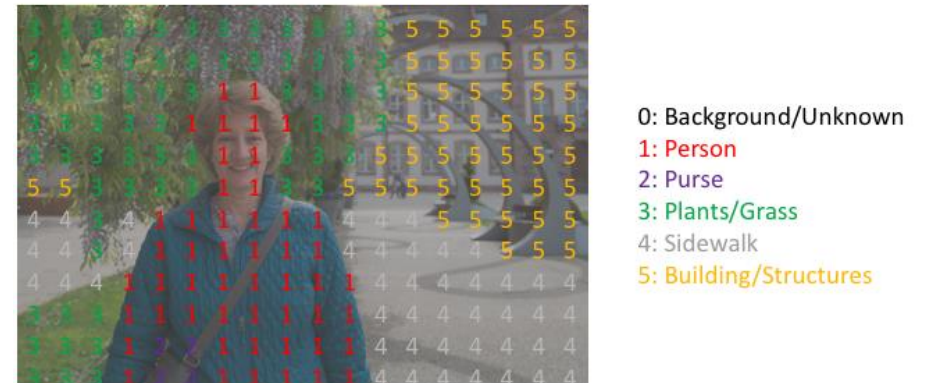


Fig. 2.

CNN의 일반적인 사용은 Classification이며 이미지에 대한 출력은 단일 클래스
하지만 생물학 이미지 처리에서 원하는 것은 Segmentation으로 각 픽셀에 라벨이 포함되어야 함

2

U-Net architecture

2.1 U-Net 구성

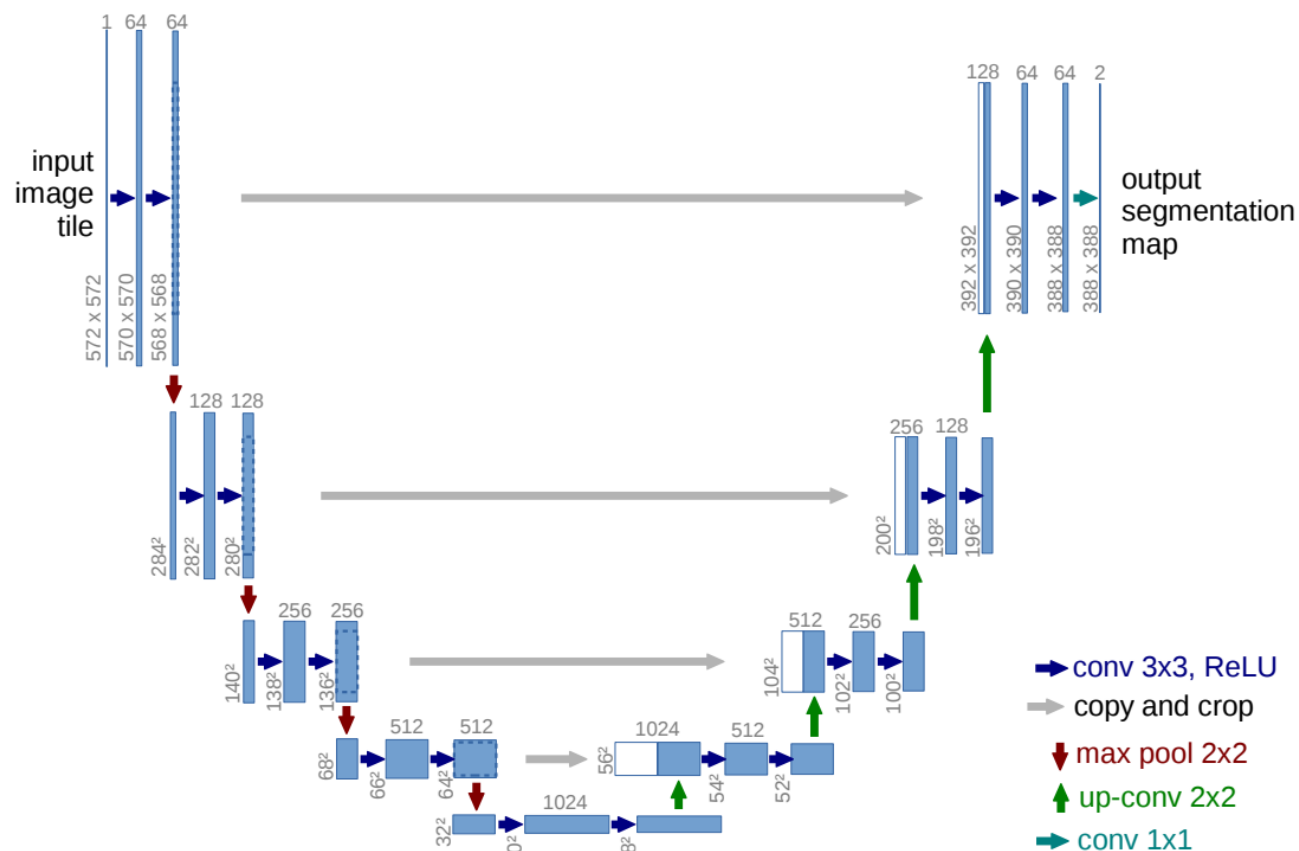


Fig. 4.

U자형으로 생긴 구조로 크게 Context 정보를 위한 Contracting path, 정확한 Localization을 위해 Expanding path로 구성

2

U-Net architecture

2.2 Contracting path

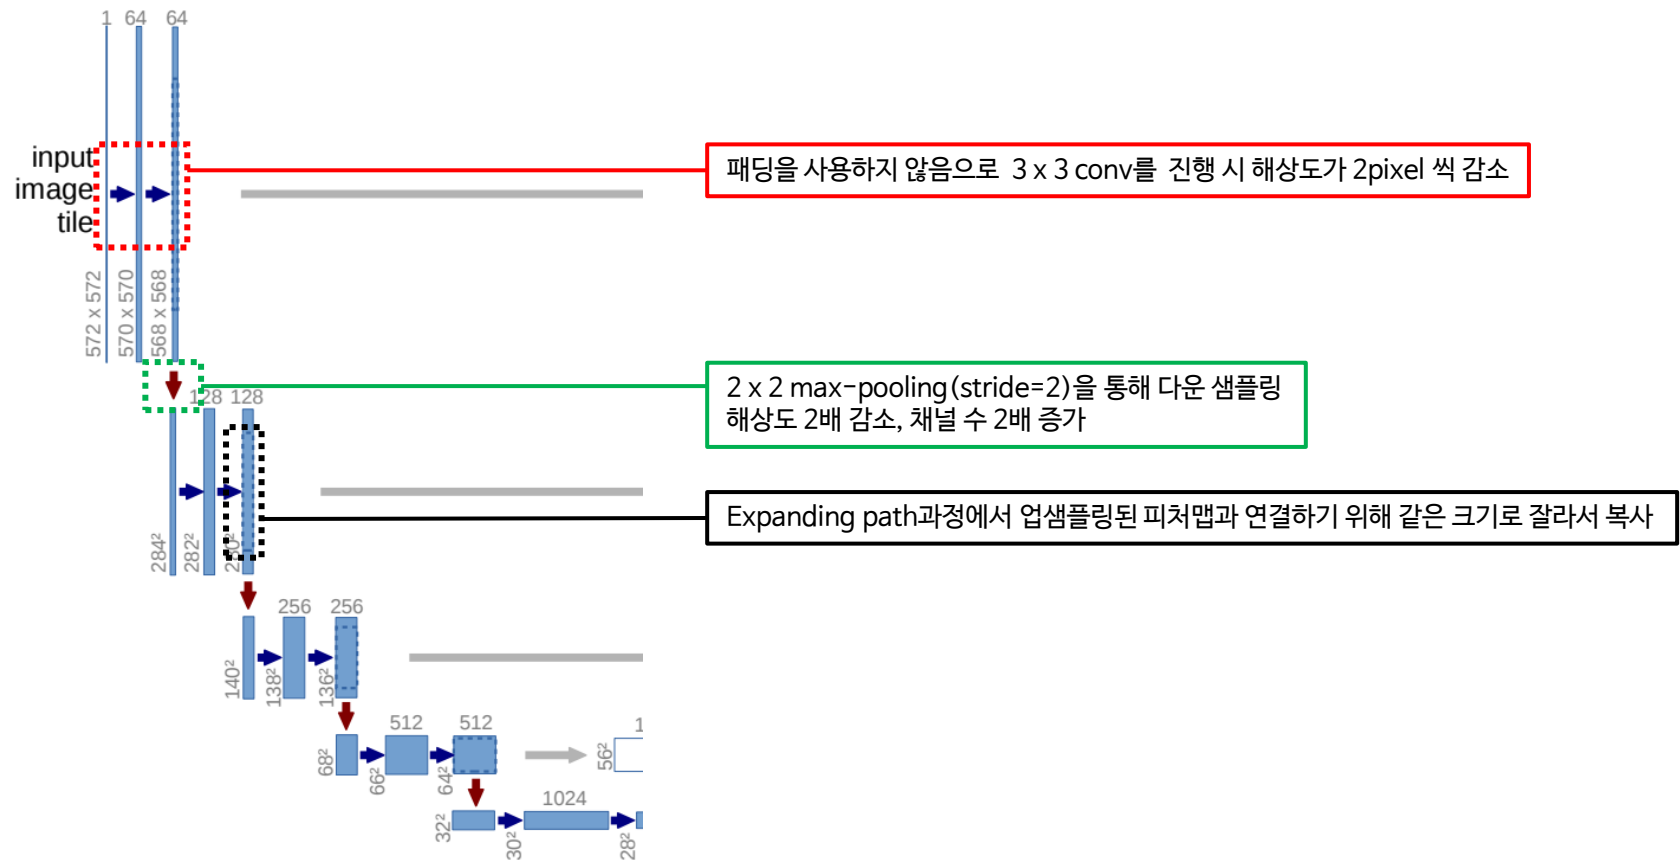


Fig. 4.

Convolution과 Relu 그리고 Maxpooling의 반복을 거치면서 Context 추출

2

U-Net architecture

2.3 Expanding path

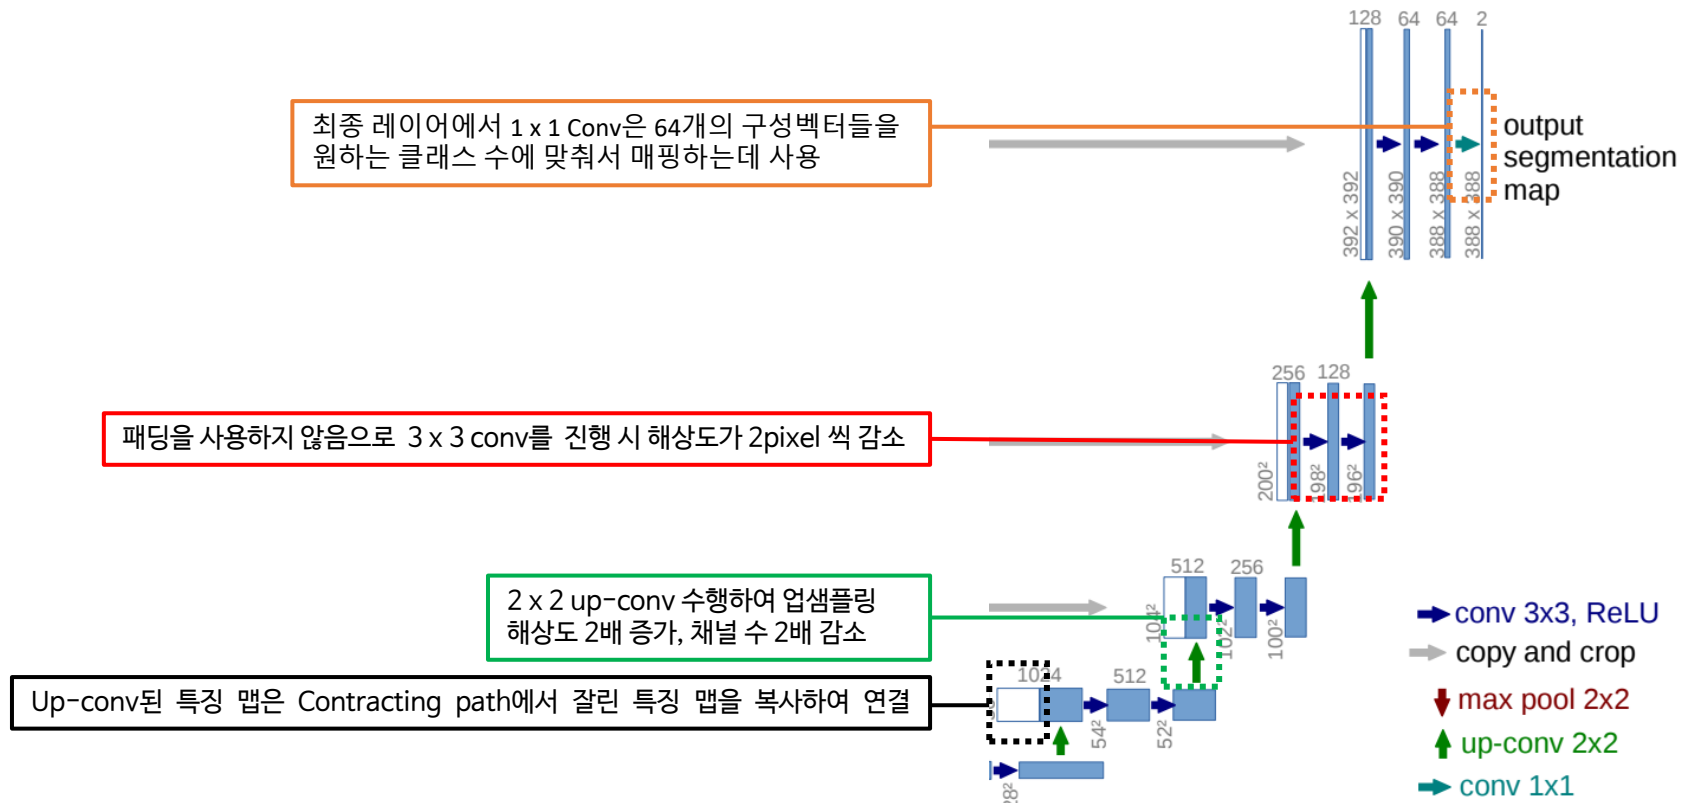


Fig. 4.

Convolution과 Relu 그리고 Up- Convolution 을 거치면서 원본 이미지와 비슷한 크기로 복원

2

U-Net architecture

2.4 U-Net 구조 특징

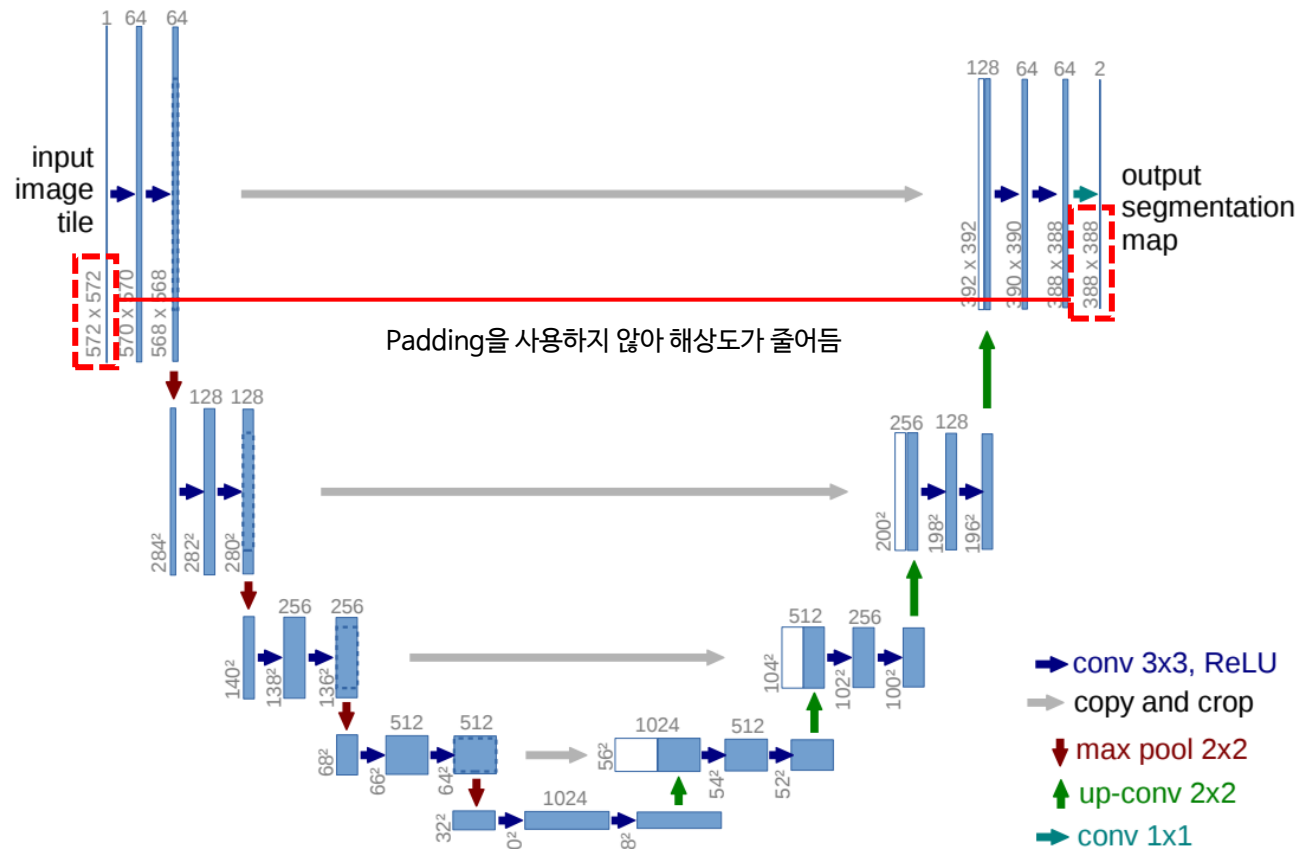


Fig. 4.

분류모델과 다르게 Fully Connected Layer가 아닌 Fully Convolutional Network로 구성
Contracting path에서 나온 Context와 Expanding path에서 나온 Localization이 결합하여 성능이 우수

3.1 Overlap-tile strategy




Fig. 5.

Fig. 5. 번처럼 노란색 영역의 Segementation을 위해 파란색 영역만큼의 입력 이미지의 비어있는 부분은 미러링을 하여 외삽하는데 이런 이유는 해상도가 큰 이미지에 대해 매끄럽게 분할이 가능하며 GPU 메모리에 의해 해상도가 제한되기 때문

4 Training

4.1 Objective function

Softmax

$$p_k(\mathbf{x}) = \exp(a_k(\mathbf{x})) / \left(\sum_{k'=1}^K \exp(a_{k'}(\mathbf{x})) \right)$$

\mathbf{x} = 픽셀의 위치(pixel position)

K = 특징 채널(feature channel) = 클래스

따라서 $a_k(\mathbf{x})$ = k 번째 채널의 \mathbf{x} 위치의 activation값

Cross entropy

$$E = \sum_{\mathbf{x} \in \Omega} w(\mathbf{x}) \log(p_{\ell(\mathbf{x})}(\mathbf{x}))$$

$w(\mathbf{x})$ = 추가적인 가중치 함수

Segmentation은 픽셀단위로 라벨링을 해야 되기 때문에 픽셀 단위로 Softmax를 사용하고 학습을 위해 Cross entropy를 사용하는데 학습이 더 잘되도록 추가적으로 가중치 함수를 사용

4 Training

4.2 Weight

$$w(\mathbf{x}) = w_c(\mathbf{x}) + w_0 \cdot \exp \left(-\frac{(d_1(\mathbf{x}) + d_2(\mathbf{x}))^2}{2\sigma^2} \right)$$

d_1 = 가장 가까운 셀의 경계까지의 거리

d_2 = 두번째로 가까운 셀의 경계까지의 거리




Fig. 6.

가중치함수의 식을 통해 d_1 , d_2 거리가 가까울수록 가중치가 증가
Fig. 7. d는 가중치를 매핑한 이미지인데 이를 통해 가까운 셀의 경계는 가중치가 더 큰 것을 확인 할 수 있음

4 Training

4.3 Data Augmentation

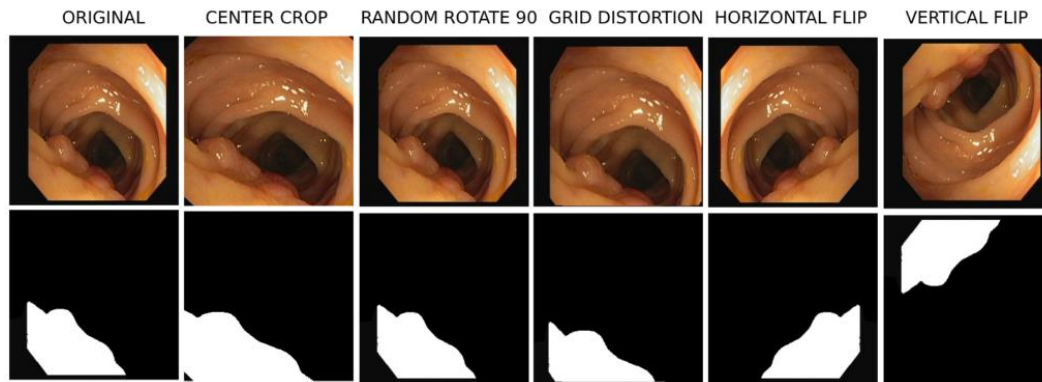



Fig. 7.



(a) Original

(b) Deformed

Fig. 8.

데이터가 부족할 땐 이미지 증강이 필수적
여기선 Fig. 8.처럼 일반적으로 사용하는 데이터 증강 외에 Fig. 9.처럼 elastic deformation을 사용

5.1 Experiments

EM segmentation challenge(2015)

Rank	Group name	Warping Error	Rand Error	Pixel Error
	** human values **	0.000005	0.0021	0.0010
1.	u-net	0.000353	0.0382	0.0611
2.	DIVE-SCI	0.000355	0.0305	0.0584
3.	IDSIA [1]	0.000420	0.0504	0.0613
4.	DIVE	0.000430	0.0545	0.0582
⋮				
10.	IDSIA-SCI	0.000653	0.0189	0.1027

ISBI cell tracking challenge(2015)

Name	PhC-U373	DIC-HeLa
IMCB-SG (2014)	0.2669	0.2935
KTH-SE (2014)	0.7953	0.4607
HOUS-US (2014)	0.5323	-
second-best 2015	0.83	0.46
u-net (2015)	0.9203	0.7756




Fig. 9.

EM segmentation challenge에선 U-Net은 데이터 전처리나 사후처리없이 Warping Error 기준으로 좋은 성능
ISBI cell tracking challenge에서는 두번째 좋은 모델과의 성능이 차이가 많이 남

6.1 Conclusion

1. U-Net은 생물의학 segmentation에서 매우 좋은 성능을 보여줌
2. Elastic deformation 덕분에 라벨링 된 데이터가 많이 필요 없었으며 합리적인 training 시간
3. U-Net architecture가 더 많은 작업에 쉽게 적용 될 것이라고 확신

6.2 Review

1. 논문 제목처럼 Biomedical 분야에서는 많이 활용되고 있을 것
2. 다른 분야도 생각해보면 위성사진에서 밀집 되어있는 주택가에서 주택의 경계선, 얽혀 있는 도로를 구분 등 사용이 가능할 것으로 보여짐